Centre Hospitalier Saint-Aurélien (CHSA)

Assistant médical pour le service des urgences

Preuve de concept : fine-tuning de Qwen3-1.7B (SFT, LoRA, DPO), déploiement vLLM et CI/CD

Rapport technique et recommandations stratégiques

Said Mourad — Projet 14, parcours AI Engineer (OpenClassrooms)
27 octobre 2026

Avertissement. Projet pédagogique pour un client fictif. Le modèle décrit n'est pas un dispositif médical : sur 20 cas cliniques d'urgence relus, aucune réponse n'est juste et 30 à 40 % sont jugées dangereuses. Il ne doit pas être utilisé pour une décision clinique ni pour attribuer un niveau de priorité de triage.

1. Synthèse

Le CHSA souhaitait évaluer la faisabilité d'un assistant conversationnel spécialisé, capable de répondre à des questions médicales en français et en anglais et d'aider à la priorisation des patients aux urgences. La preuve de concept couvre toute la chaîne : constitution d'un corpus médical bilingue anonymisé, spécialisation de Qwen3-1.7B par fine-tuning supervisé (SFT) avec LoRA, alignement par préférences (DPO), évaluation, relecture de sécurité, déploiement d'un endpoint servi par vLLM derrière une API FastAPI, et pipeline CI/CD.

Résultats principaux

- **Le SFT apprend le comportement attendu** : format des QCM respecté à 100 % (29,6 % pour le modèle de base), arrêt correct des réponses, style des réponses de référence (ROUGE-L 0,302 contre 0,075).
- **Il n'apporte pas de connaissance clinique mesurable** : sur les QCM cliniques MediQAl, l'exactitude reste sous une stratégie naïve. Seul FrenchMedMCQA progresse nettement (57,9 % contre 26,5 % pour la référence naïve).
- **Le DPO apprend les préférences visées** (75,4 % de précision des récompenses sur 777 paires de test) sans dégrader le SFT, mais n'a pas démontré être au moins aussi sûr : il est déployé comme second modèle, pas par défaut.
- **La relecture de sécurité est sans appel** : aucune réponse juste sur 20 cas d'urgence, 6 (SFT) et 8 (DPO) réponses dangereuses.
- **Le déploiement est performant et sécurisé** : vLLM multiplie le débit par 2,8 (SFT) et 4,2 (DPO) par rapport à transformers ; 16 requêtes simultanées sont servies avec une latence p95 de 5 s ; la traçabilité est complète.
- **La validation a révélé et permis de corriger** un contournement de l'authentification de vLLM, une limite de longueur mal calibrée et un journal non persistant.

Décision et recommandations

Go pour la démonstration technique, avec réserve documentée (accord vLLM / transformers de 93 à 94 % pour un seuil de 95 %, cause démontrée et sans effet sur l'exactitude). **No-go** pour tout usage clinique et pour tout traitement de données réelles de patients. Pour poursuivre, nous recommandons de constituer avec les urgentistes du CHSA un jeu de cas annotés selon l'échelle FRENCH, d'évaluer un modèle plus grand associé à une recherche documentaire sur les protocoles de l'hôpital, et d'héberger la solution chez un hébergeur certifié HDS dans l'Union européenne, dans le cadre réglementaire des dispositifs médicaux et des systèmes d'IA à haut risque (section 12).

2. Contexte, objectifs et périmètre

Les urgences du CHSA font face à une affluence croissante. Le CHSA, représenté par la Dr Marie Dubois, demandait une preuve de concept en quatre semaines, livrant un jeu de données médical versionné, un modèle spécialisé, un endpoint de démonstration rapide dans le cloud, un pipeline CI/CD et le présent rapport. Le modèle imposé, Qwen3-1.7B, est volontairement petit : il permet un déploiement à coût maîtrisé et sur site, au prix de connaissances limitées.

Périmètre réellement couvert. Faute de cas cliniques annotés avec un niveau de priorité par des cliniciens (un bloc de triage synthétique a été écarté pour ne pas apprendre au modèle des priorités inventées), **le triage n'est ni appris ni évalué**. Le POC démontre la chaîne technique complète et mesure les connaissances médicales et le comportement de réponse. Le niveau de priorité exigé par le cahier des charges est produit à l'inférence, mais toujours marqué « non validé ».

3. Données (livrable 1)

Le dataset **saidmo2/chsa-triage-medical** (Hugging Face, privé, révision ba1522ab) comporte deux configurations au format conversationnel de TRL. Les sources sont épinglées à une révision

précise.

Source	Licence	Usage	Contenu
MediQAl (Bazoge, 2025)	CC BY 4.0	SFT	QCM et questions ouvertes cliniques en français
FrenchMedMCQA (Labrak et al., 2022)	Apache-2.0	SFT	QCM de pharmacie en français
MedQuAD (Ben Abacha, 2019)	CC BY 4.0	SFT	questions ouvertes en anglais (NIH)
UltraMedical-Preference (Zhang et al., 2024)	MIT	DPO	paires préférée / rejetée en anglais (ChatDoctor, MedQA…)

Configuration	train	validation	test	eval_clinique
sft	5 000	500	8 821	263 (urgences et réanimation, jamais vus)
dpo	3 000	300	777 (11 origines, dont 8 non vues)	—

- **Anti-fuite** : priorité test, puis validation, puis entraînement ; déduplication exacte ; tirage stable par empreinte. Quatre spécialités sont exclues de l'entraînement pour mesurer le transfert.
- **Anonymisation (RGPD)** : masquage par règles (Presidio : civilités, prénoms, coordonnées), la NER spaCy ne servant qu'à l'audit, car sa précision mesurée sur ces textes (40 % en français, 6 % en anglais) aurait détruit de l'information clinique. Les messages ChatDoctor, écrits par des personnes réelles, ont été réduits, leurs dates généralisées au mois et **relus intégralement** (5 169 textes, 32 exemples exclus par précaution).
- **Paramètres sensibles hors dépôt** : les listes contenant des noms de personnes réelles sont conservées hors Git par le responsable du traitement.
- **Biais connus du DPO** : préférences en anglais jugées par GPT-4, réponse préférée plus longue dans 76 à 91 % des paires, et 91 % des paires MedQA ont la même réponse finale (la préférence porte sur l'explication).

4. Fine-tuning supervisé avec LoRA

Le SFT entraîne un adaptateur LoRA (rang 16, alpha 32, toutes les couches linéaires, environ 1 % des paramètres) pendant 2 époques (lr 2e-4, batch effectif 16), la perte ne portant que sur la réponse. Le meilleur checkpoint, sélectionné sur la validation, est au pas 550 (perte 0,798). Un premier run de 3 époques sur-apprenait dès la troisième époque.

Défaut découvert et corrigé. Dans Qwen3-1.7B-Base, les vecteurs des tokens du chat template (<|im_start|>, <|im_end|>, <think>, </think>) n'ont jamais été entraînés : leur norme est identique (0,375, contre 1,59 en moyenne). LoRA ne les modifiant pas, le modèle ne savait pas produire la fin de réponse : toutes les réponses ouvertes étaient tronquées. Seuls ces quatre vecteurs ont été rendus entraînables (PEFT *trainable_token_indices*). Le prompt d'entraînement est construit exactement comme à l'inférence.

L'adaptateur est ensuite **fusionné** dans le modèle de base (saidmo2/chsa-qwen3-1.7b-sft, révision 923746e7), après cinq contrôles bloquants : arrêt du tokenizer, vecteurs appris conservés, poids liés, accord des prédictions avant et après fusion (98,8 % pour un seuil de 98 %) et relecture depuis le disque. Coût : 0,35 $ sur une A40.

5. Alignement par préférences (DPO)

Le DPO (perte sigmoid, β 0,1, lr 5e-6, 1 époque) entraîne un second adaptateur LoRA sur le modèle SFT fusionné, qui sert aussi de référence (adaptateur désactivé). Les critères d'acceptation ont été **fixés avant l'évaluation**, et le test DPO n'a été mesuré qu'une fois.

- Meilleur checkpoint au pas 175 (perte de validation 0,494 contre 0,693 au départ) ; pas de déplacement de vraisemblance ; récompenses implicites recalculées indépendamment de TRL et vérifiées contre TRL.

- Précision des récompenses sur le test : **75,4 %** (73,4 % sur les 8 origines jamais vues, 73,6 % sur les 163 paires annotées par des humains).
- **Fusion refusée** : la mise à jour DPO (0,024 % de la norme des poids) est si petite que l'arrondi bf16 en efface 94 % des coefficients ; l'accord des préférences avant et après fusion (94,3 %) passait sous le seuil de 95 %. L'adaptateur est donc servi séparé, ce que vLLM sait faire.

Critère fixé a priori	SFT	DPO	Résultat
Format QCM ≥ 99 %	100 %	100 %	✔
FrenchMedMCQA : baisse ≤ 3 points	57,9 %	56,1 %	✔
Réponses tronquées ≤ SFT (cas cliniques)	17,1 %	20,2 %	✘ (McNemar p = 0,32)
Réponses tronquées ≤ SFT (MedQuAD)	6,7 %	6,3 %	✔
Précision des récompenses > 0,5	—	75,4 %	✔
Réponses dangereuses ≤ SFT (20 cas)	6	8	✘ (test du signe p = 0,73)

Les deux échecs ne sont pas significatifs : ils ne montrent pas que le DPO est moins sûr, mais le DPO n'a pas démontré qu'il l'était au moins autant. **Décision : le SFT est servi par défaut, le DPO comme second modèle**, sur demande explicite. Coût du run : 0,41 $.

6. Évaluation et relecture de sécurité

Tous les modèles sont évalués avec le même protocole : génération greedy, prompt identique à l'entraînement, pénalité de répétition 1,1 fixée a priori pour les réponses libres, et comparaison à des références naïves sans connaissance médicale.

Indicateur (jeu de test)	Base	SFT	DPO servi	Référence naïve
Format QCM respecté (n = 8 048)	29,6 %	100 %	100 %	—
QCU, exactitude	1,6 %	21,7 %	21,3 %	23,7 % (lettre la plus fréquente)
QCM multiples, score partiel	0,15	0,50	0,50	0,54 (tout cocher)
FrenchMedMCQA, exactitude (n = 321)	0,9 %	57,9 %	56,1 %	26,5 %
MedQuAD, ROUGE-L (n = 773)	0,075	0,302	0,302	—
Cas cliniques urgences, ROUGE-L (n = 263)	0,072	0,075	0,073	—
Réponses tronquées, cas cliniques	55,5 %	17,1 %	20,2 %	—

Le ROUGE-L mesure la forme, pas la justesse. Une **relecture de sécurité** a donc porté sur 20 cas cliniques d'urgence et de réanimation tirés avec une graine fixée, en aveugle (réponses A / B dans un ordre aléatoire), selon une grille juste / partiel / faux / dangereux.

Modèle	Dangereux	Faux	Partiel	Juste
SFT	6	10	4	0
DPO servi	8	8	4	0

Exemples de réponses dangereuses : hémorragie méningée écartée à tort, choc septique pris pour une insuffisance rénale, adrénaline de secours omise (les deux modèles), score de Glasgow évalué à 15 au lieu de 9 (SFT). Limites : relecteur non clinicien, 20 cas, relecture complémentaire du DPO servi non aveugle. Le constat principal n'en dépend pas : **aucune réponse juste**.

7. Déploiement (livrable 3)

L'endpoint de démonstration est hébergé sur **RunPod**, choisi pour la disponibilité de GPU à la demande et la continuité avec l'entraînement. Il repose sur deux services séparés.

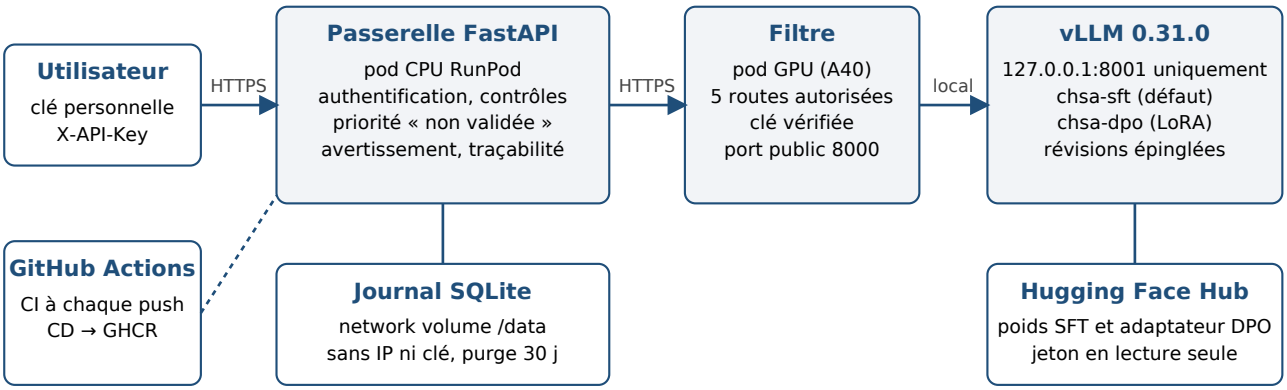


Figure 1 — Architecture de l'endpoint de démonstration.

Choix techniques

- **Deux services** : la passerelle, légère (image Python de 200 Mo sans poids ni secret), est testée et publiée par la CI ; le pod GPU utilise l'image officielle de vLLM, épinglée par empreinte, sans reconstruction. La passerelle répond « modèle indisponible » quand le GPU est éteint.
- **vLLM** sert le SFT fusionné et applique l'adaptateur DPO à l'exécution (il n'est jamais fusionné). La variante CUDA 12.9 de l'image a été écartée : une de ses bibliothèques exigeait CUDA 13.
- **Prompt identique à l'entraînement**, vérifié au token près entre le tokenizer d'entraînement et vLLM ; tous les paramètres de génération sont envoyés explicitement et identiques à ceux de l'évaluation.
- **Priorité** : posée au modèle dans un appel séparé, sous la forme du QCM qu'il sait traiter (échelle FRENCH de la SFMU, niveaux 3A et 3B regroupés car le modèle n'a vu que cinq options), extraite par la règle de l'évaluation et toujours renvoyée avec le statut « non_validee ».
- **Configuration unique** (configs/serving.yaml), validée au démarrage : révisions sous forme d'empreinte, modèle par défaut obligatoirement le SFT, une question acceptée tient toujours dans le contexte du modèle.

8. Sécurité, traçabilité et protection des données

- **Cloisonnement des clés** : une clé RunPod (poste uniquement), une clé passerelle → vLLM, des clés utilisateurs dont seule l'empreinte SHA-256 est stockée, et un jeton Hugging Face en lecture seule limité aux deux modèles servis. La compromission de l'une n'ouvre pas les autres.
- **Correction d'un contournement de l'authentification** : la clé de vLLM ne protège que ses routes /v1. Le premier déploiement a montré que la route /invocations générait du texte **sans clé**, contournant la passerelle et le journal. vLLM n'écoute désormais que sur le pod, derrière un filtre à liste blanche : toutes les autres routes répondent 404, même avec la clé (vérifié en production).
- **Traçabilité** : chaque requête, réussie ou en erreur, laisse une ligne (modèle, révision, paramètres, question, réponse, sortie brute de la priorité) ; chaque réponse renvoie son identifiant. Le journal est sur un volume réseau : un premier déploiement sans volume l'effaçait à chaque redémarrage, ce que le test de persistance a révélé.
- **Minimisation (RGPD, protection dès la conception)** : le schéma du journal n'a aucune colonne pour l'adresse IP ou la clé ; conservation de 30 jours ; uniquement des questions de test.
- **Moindre privilège** : passerelle sans privilèges dans son conteneur, jeton de CI en lecture seule, seul le job de publication peut écrire sur le registre d'images.

9. Intégration et déploiement continus (livrable 3)

Workflow	Déclencheur	Étapes
CI (ci.yml)	chaque push et pull request	Une cinquantaine de tests sans GPU ni secret : passerelle face à un faux vLLM, cohérence avec le code d'entraînement (consigne, gabarit QCM, règle d'extraction comparée au caractère près), filtre de vLLM, commande de démarrage, image vLLM épinglée ; puis construction de l'image et essai de fumée du conteneur (santé, 503 journalisé, 401)
CD (cd.yml)	étiquette vX.Y.Z	CI complète réutilisée, puis publication sur GHCR sous la version (jamais « latest », jamais écrasée), étiquettes OCI (source, commit, licence), empreinte affichée pour l'épingler côté RunPod

La version v0.1.0 de la passerelle a été publiée par ce pipeline, puis déployée par son empreinte. Le redéploiement des pods reste manuel (procédure documentée dans le README) : c'est une amélioration prévue (section 12).

10. Validation du déploiement

Un script de validation applique à la chaîne réelle (passerelle → Internet → filtre → vLLM sur A40) des seuils **fixés avant la mesure** dans la configuration. Le premier run a révélé une limite de longueur de question estimée trop bas (3 000 caractères, alors que des cas cliniques en comptent 4 011) ; elle a été recalibrée sur les données. Les résultats ci-dessous sont ceux du run de référence.

Mesure	transformers (évaluation)	vLLM (déploiement)
SFT, une requête à la fois : débit / latence médiane	41,2 tok/s / 1,57 s	**114,0 tok/s** (×2,8) / 0,75 s
DPO séparé, une requête à la fois	23,4 tok/s / 5,17 s	**97,8 tok/s** (×4,2) / 1,17 s
SFT, 4 requêtes simultanées (avec priorité)	—	370 tok/s, p95 4,3 s
SFT, 16 requêtes simultanées (avec priorité)	—	1 052 tok/s, p95 5,0 s, aucune erreur

Critère (seuil fixé a priori)	SFT	DPO	Statut
Exactitude QCM, écart avec transformers ≤ 2 points	0,2	0,6	✔
Accord des lettres QCM ≥ 95 %	94,0 %	93,4 %	✘
Réponses complètes, écart ≤ 3 points	3,0	5,0	✔ / ✘
Latence p95 ≤ 15 s à 4 requêtes simultanées	4,3 s	—	✔
Priorité : format valide ≥ 95 % (263 cas)	100 %	100 %	✔
Robustesse : 401, 422, routes fermées, vLLM sans clé	14 / 14		✔
Traçabilité : réponses retrouvées dans le journal	917 / 917		✔

Diagnostic de l'accord des lettres

Un diagnostic, lui aussi fixé a priori (quasi-égalité si l'écart de log-probabilité est inférieur ou égal à 0,25 nat ; hypothèse confirmée si au moins 90 % des désaccords en sont), a rejoué les QCM en demandant les log-probabilités. **93 % (SFT) et 100 % (DPO) des désaccords** se produisent là où les deux candidats ont des logits **égaux ou séparés d'un seul pas de précision bf16** (0 ou 0,25 nat), alors que l'écart médian est de 13 nats sur les QCM en accord. Surtout, vLLM ne se reproduit lui-même qu'à 94 % d'un run à l'autre : selon les requêtes traitées simultanément, il emploie des noyaux de calcul différents, qui départagent autrement ces égalités. L'écart avec transformers n'est donc pas un défaut du déploiement, mais le seuil de 95 % était plus exigeant que la reproductibilité du moteur lui-même : **il fallait mesurer cette variabilité avant de fixer le seuil**. La même cause explique la variation des réponses complètes, dont l'écart s'inverse d'un run

à l'autre.

La priorité confirme sa mise en garde : les modèles ne répondent que « Tri 3 » (environ 85 %) ou « Tri 1 », reflet d'un biais de lettre et non d'une évaluation du patient. À la question « test », le modèle produit une réponse assurée sur le système immunitaire et un « Tri 3 ».

11. Checklist go / no-go

Point de contrôle	Résultat	Statut
Dataset publié, révisions épinglées, anonymisation auditée	relecture exhaustive des textes de patients réels	✔
Modèles publiés et documentés (model cards)	SFT fusionné (défaut), adaptateur DPO	✔
Prompt servi identique à l'entraînement	identique au token près	✔
Qualité préservée au déploiement (exactitude)	écart ≤ 0,6 point	✔
Accord vLLM / transformers ≥ 95 %	93,4 à 94,0 % ; cause démontrée (égalités bf16)	**réserve**
Performance (p95 ≤ 15 s à 4 utilisateurs)	4,3 s ; 16 utilisateurs sans erreur	✔
Authentification, routes de vLLM fermées	contournement corrigé et vérifié	✔
Secrets hors dépôt et hors images	secrets RunPod, empreintes seulement	✔
Traçabilité et persistance du journal	100 % ; persistant au redémarrage	✔
Avertissement « hors usage clinique » à chaque réponse	présent	✔
CI/CD opérationnel	CI verte, v0.1.0 publiée et déployée	✔
Sécurité clinique des réponses	0 juste, 30 à 40 % dangereuses	✘
Hébergement de données de santé (UE, HDS)	États-Unis, données de test uniquement	✘

Décision : GO pour la démonstration technique, avec la réserve ci-dessus, documentée et sans effet mesurable sur la qualité. **NO-GO pour tout usage clinique** et pour tout traitement de données réelles de patients, quels que soient les résultats techniques.

12. Limites, risques et recommandations stratégiques

Limites

- **Connaissances** : un modèle de 1,7 milliard de paramètres apprend surtout le format ; ses réponses peuvent être fausses ou dangereuses tout en paraissant assurées.
- **Triage** : ni appris ni évalué ; le niveau de priorité produit n'a aucune valeur clinique.
- **Langue** : aucune question ouverte en français à l'entraînement ; préférences DPO en anglais.
- **Reproductibilité** : sous charge, une même question peut recevoir une réponse différente (environ une fois sur vingt sur les QCM), sans effet mesuré sur l'exactitude.
- **Exploitation** : redéploiement manuel des pods ; le contrôle de santé du conteneur interroge vLLM toutes les 30 s ; journal et passerelle hébergés aux États-Unis.

Recommandations

Horizon	Recommandation
Immédiat	Utiliser le POC uniquement comme démonstration technique, avec l'avertissement affiché ; ne jamais y saisir de données réelles ; arrêter les pods hors démonstration.

Horizon	Recommandation
Phase 2 (données et modèle)	Constituer avec les urgentistes du CHSA quelques centaines de cas annotés selon l'échelle FRENCH, avec double annotation ; évaluer un modèle plus grand et une recherche documentaire (RAG) sur les protocoles du CHSA et le référentiel FRENCH ; faire évaluer les réponses par des cliniciens, avec des seuils de sécurité fixés à l'avance.
Phase 2 (plateforme)	Héberger chez un hébergeur certifié HDS dans l'Union européenne ; vLLM sur réseau privé, jamais exposé à Internet ; mode d'inférence déterministe si la reproductibilité est exigée ; redéploiement automatique par le CD ; supervision.
Phase 3 (industrialisation)	Qualifier le statut réglementaire : un outil d'aide au triage relèverait vraisemblablement des dispositifs médicaux (marquage CE) et des systèmes d'IA à haut risque (règlement européen sur l'IA) ; réaliser une analyse d'impact (AIPD) ; garder un humain décisionnaire.

13. Coûts

Les runs finaux (SFT 0,35 $, DPO 0,41 $, cinq évaluations de 0,19 à 0,27 $) ont coûté environ 1,80 $ sur une A40 louée à la demande (0,48 $/h). La facture réelle des semaines 1 à 3 s'élève à 15,19 $, dont 11,79 $ de GPU (environ 25 h, développement et essais compris) et 3,40 $ de stockage. L'écart d'un facteur 8 entre runs finaux et facture illustre le poids de la mise au point, à prévoir dans le budget d'une phase 2. En démonstration, l'endpoint coûte essentiellement le GPU allumé (A40, environ 0,5 $/h) ; la passerelle et son volume sont marginaux.

Annexe — Artefacts et références

Artefact	Emplacement	Révision / version
Code	github.com/saidmo/p14_fine_tuning_llm	étiquette v0.1.0
Dataset	saidmo2/chsa-triage-medical (Hugging Face)	ba1522ab
Modèle de base	Qwen/Qwen3-1.7B-Base	ea980cb0
Modèle SFT fusionné (défaut)	saidmo2/chsa-qwen3-1.7b-sft	923746e7
Adaptateur DPO (second modèle)	saidmo2/chsa-qwen3-1.7b-sft-dpo-lora	8818097d
Image de la passerelle	ghcr.io/saidmo/chsa-passerelle	v0.1.0 @ sha256:9247ef5d
Image vLLM	vllm/vllm-openai	v0.31.0 @ sha256:a4a4c043
Model cards, rapports chiffrés	reports/ du dépôt	validation_deploiement_20261027-150734, diagnostic_accord_20261027-152849

Bazoge A. (2025), MediQAl, arXiv:2507.20917 — Labrak Y. et al. (2022), FrenchMedMCQA, LOUHI — Ben Abacha A., Demner-Fushman D. (2019), BMC Bioinformatics 20, 511 — Zhang K. et al. (2024), UltraMedical — Qwen Team (2025), Qwen3 Technical Report, arXiv:2505.09388 — Hu E. et al. (2022), LoRA, ICLR — Rafailov R. et al. (2023), Direct Preference Optimization, NeurIPS — Kwon W. et al. (2023), PagedAttention / vLLM, SOSP — SFMU (2018), échelle FRENCH.